

Segmentación Automática de Tumores Cerebrales mediante IA

Arquitectura U-Net + ResNet50 para diagnóstico asistido por inteligencia artificial

Autores: Adrian Herrera, Brian Chiru

Universidad Latina de Panamá · Ingeniería Biomédica



El Desafío del Diagnóstico Manual



Segmentación manual

Proceso lento y tedioso para radiólogos

Variabilidad diagnóstica

Resultados inconsistentes entre especialistas

Tiempo crítico

La detección temprana salva vidas



Solución Tecnológica

Deep Learning en Imágenes Biomédicas

01

Automatización del proceso

Segmentación píxel a píxel mediante
redes neuronales

02

Segunda opinión objetiva

Asistencia rápida y consistente para
médicos

03

Transfer Learning

Aprovechamiento de conocimiento pre-entrenado



Metodología: Cuatro Etapas Clave



Preprocesamiento

Normalización de imágenes MRI



Arquitectura

U-Net + ResNet50



Entrenamiento

Optimización con Dice Loss



Aplicación

Software de escritorio

Arquitectura Híbrida U-Net + ResNet50

Encoder

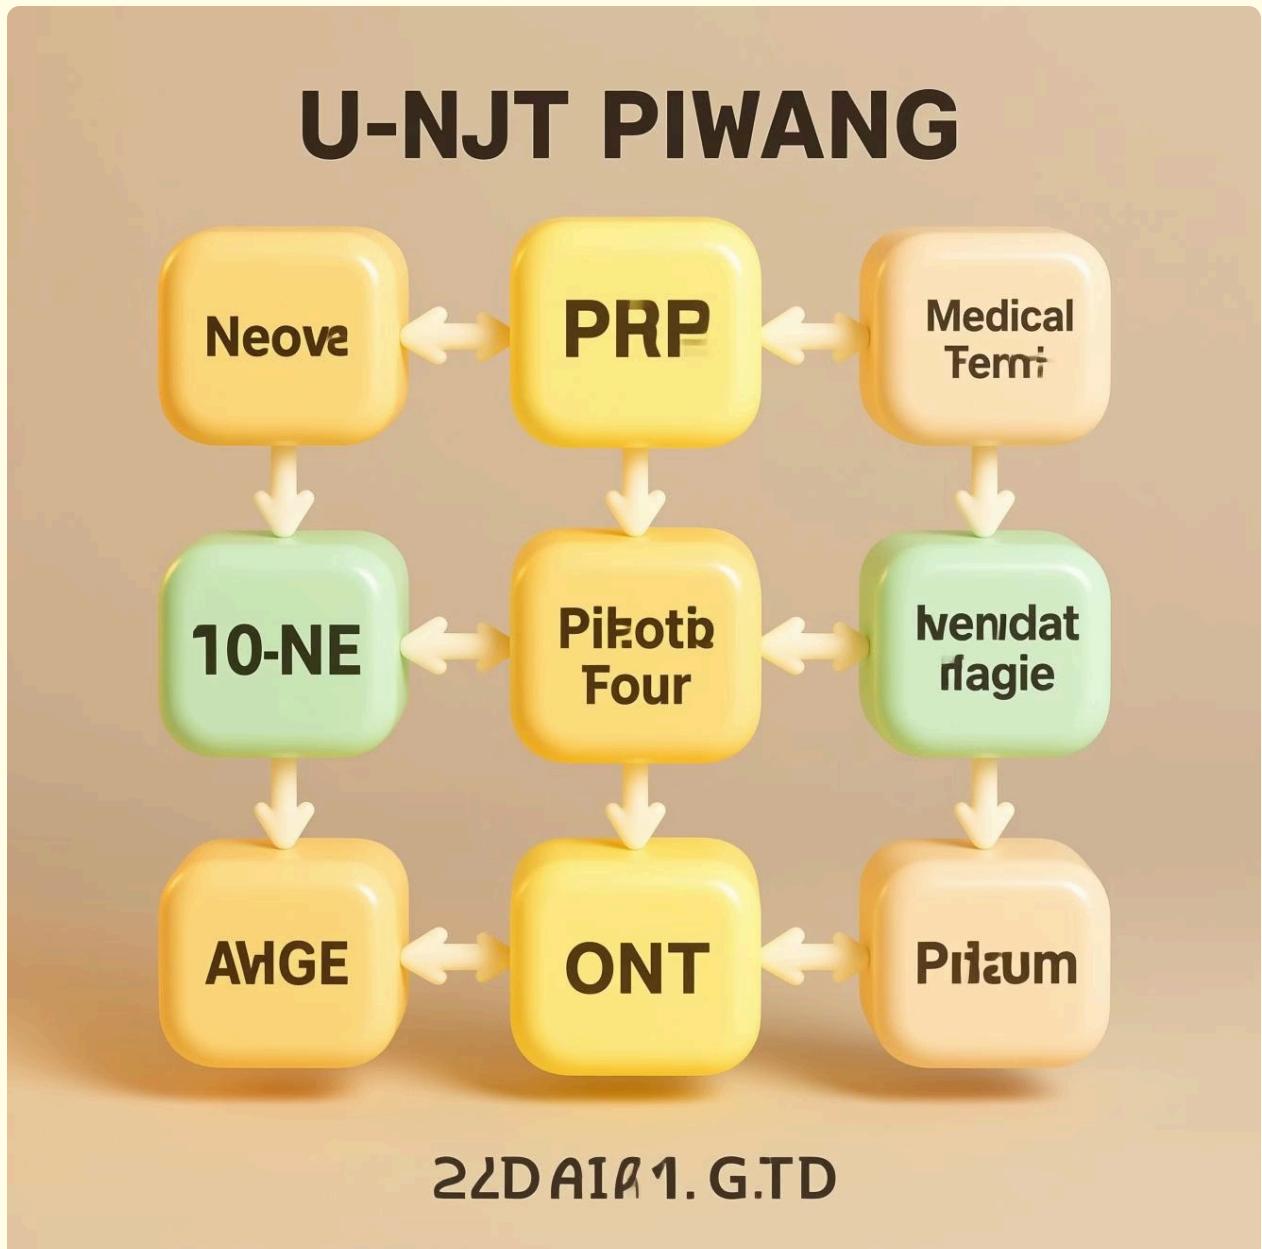
ResNet50 pre-entrenada con pesos ImageNet

- Extracción de características complejas
- Detección de bordes sutiles
- Transfer Learning aplicado

Decoder

Conv2DTranspose para recuperar resolución

- Reconstrucción espacial
- Skip connections residuales



- **Resolución:** 256 x 256 píxeles · **Normalización:** Valores escalados [0, 1] · **Framework:** TensorFlow/Keras



Resultados: Métricas de Rendimiento

99.4..

Accuracy

Exactitud global de clasificación píxel

0.79

Dice Score

F1-Score de segmentación tumoral

85%

Recall

Sensibilidad en detección completa

0.71

IoU

Intersección sobre Unión (Jaccard)

Validación Visual: MRI vs Segmentación IA

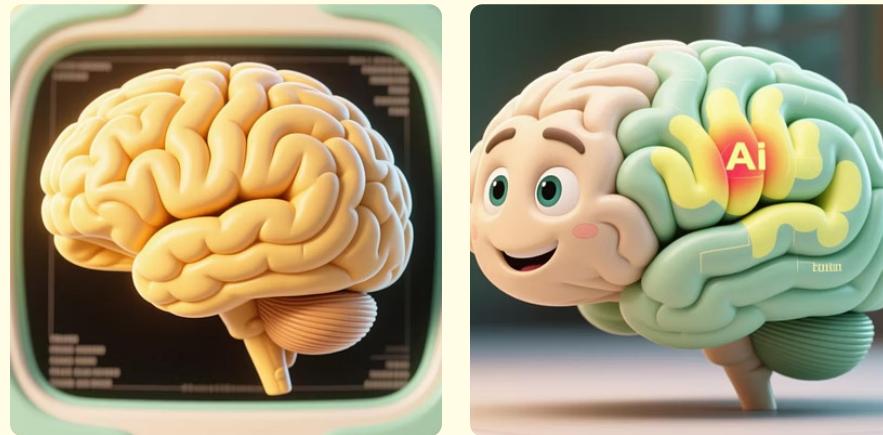
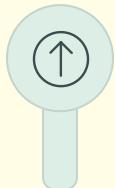


Imagen no incluida en entrenamiento · Visualización comparativa con mapa de calor que resalta tejido tumoral en contraste con tejido sano

Aplicación de Escritorio: Pipeline Técnico



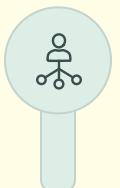
Carga del Modelo

Inyección de función `dice_loss` personalizada



Preprocesamiento

Redimensionamiento 256×256 y normalización [0,1]



Inferencia Neuronal

Matriz de probabilidades por píxel



Generación Heatmap

Colorización `cv2.COLORMAP_JET` fusionada



Visualización Comparativa

Interfaz lado a lado para validación médica

Stack Tecnológico

Pila de Desarrollo y Herramientas



Python 3.10

Lenguaje base del sistema



TensorFlow/Keras

Carga e inferencia del modelo



OpenCV

Preprocesamiento de imágenes



NumPy

Operaciones tensoriales eficientes



Pillow

Gestión de formatos y rendering

Conclusiones y Pasos Futuros

Logros del Proyecto

- **Sensibilidad del 85%**: crucial para no omitir regiones patológicas
- **Sistema funcional** sin hardware costoso de servidor
- **Base sólida** para apoyo a decisión clínica en Panamá

Requerimientos para Uso Clínico

- **Validación prospectiva con casos reales**
- **Aprobación de comités éticos institucionales**
- **Certificación regulatoria oficial**
- **Estudios de impacto clínico documentado**



- **Referencias clave:** Ronneberger et al. (U-Net, 2015) · He et al. (ResNet, 2016) · Isensee et al. (nnU-Net, 2021)