



“Desarrollo de una Aplicación de Segmentación de Tumores Cerebrales mediante Arquitectura U-Net con ResNet50”

Autores: Adrian Herrera, Brian Chiru.
adeherrera@est.ulatina.edu.pa

Estudiantes de Ingeniería Biomédica, Universidad Latina de Panamá

Abstract: The diagnosis and treatment of brain tumors rely heavily on the precise delineation of the affected area in Magnetic Resonance Imaging (MRI). This project presents the development of an AI-assisted software system for automatic tumor segmentation. A hybrid convolutional neural network architecture was implemented, combining the U-Net structure with a pre-trained ResNet50 encoder to optimize feature extraction. The model was trained and validated using a dataset of MRI images, achieving a Dice Score (F1-Score) of 0.79 and an accuracy of 99.4%. Finally, the model was integrated into an intuitive desktop application that allows specialists to visualize segmentation in real-time, facilitating the clinical workflow.

Resumen: El diagnóstico y tratamiento de tumores cerebrales dependen en gran medida de la precisión en la delimitación de la zona afectada en imágenes de resonancia magnética (MRI). Este proyecto presenta el desarrollo de un sistema de software asistido por Inteligencia Artificial para la segmentación automática de tumores. Se implementó una arquitectura de red neuronal convolucional híbrida, combinando la estructura U-Net con un codificador ResNet50 pre-entrenado para optimizar la extracción de características. El modelo fue entrenado y validado utilizando un conjunto de datos de imágenes MRI, logrando un coeficiente Dice (F1-Score) de 0.79 y una exactitud del 99.4%. Finalmente, el modelo se integró en una aplicación de escritorio intuitiva que permite a los especialistas visualizar la segmentación en tiempo real, facilitando el flujo de trabajo clínico.

Keywords: Semantic Segmentation, U-Net, ResNet50, Brain Tumor, MRI, Artificial Intelligence, Biomedical Engineering.

Palabras Clave: Segmentación Semántica, U-Net, ResNet50, Tumor Cerebral, MRI, Inteligencia Artificial, Ingeniería Biomédica.

I. INTRODUCCIÓN

Los tumores cerebrales representan una patología crítica donde la detección temprana y precisa es fundamental para la supervivencia del paciente. El análisis de imágenes de resonancia magnética (MRI) es el estándar de oro para el

diagnóstico; sin embargo, la segmentación manual (dibujar el contorno del tumor) es un proceso lento, tedioso y sujeto a la variabilidad entre distintos radiólogos.

En el contexto de la Ingeniería Biomédica, la aplicación de técnicas de *Deep Learning* (Aprendizaje Profundo) ofrece una solución automatizada. Este proyecto tiene como objetivo desarrollar una herramienta de software capaz de identificar y segmentar tumores cerebrales pixel a pixel, proporcionando una "segunda opinión" rápida y objetiva al personal médico. A diferencia de enfoques tradicionales, se propone el uso de *Transfer Learning* mediante la arquitectura ResNet50 integrada en una red U-Net para mejorar la precisión en imágenes médicas complejas.

II. METODOLOGÍA

El desarrollo del proyecto se dividió en cuatro etapas principales: Preprocesamiento de datos, Diseño de la Arquitectura, Entrenamiento y Desarrollo de la Aplicación.

A. Conjunto de Datos (Dataset)

Se utilizó un conjunto de datos de imágenes de resonancia magnética cerebral que incluye las imágenes originales y sus correspondientes máscaras binarias (ground truth).

- **Total de imágenes:** Se procesaron miles de cortes tomográficos.

- **División:** Los datos se separaron en conjuntos de Entrenamiento (Train), Validación (Validation) y Prueba (Test) para garantizar una evaluación objetiva.

B. Preprocesamiento

Las imágenes médicas varían en resolución y contraste. Se aplicó un proceso de estandarización:

1. **Redimensionamiento:** Todas las imágenes fueron ajustadas a una resolución espacial de 256 x 256 píxeles para reducir la carga computacional de la GPU.
2. **Normalización:** Los valores de los píxeles se escalaron a un rango de [0, 1] dividiendo por 255, facilitando la convergencia matemática de la red neuronal.

C. Arquitectura del Modelo (U-Net + ResNet50)

Se diseñó una red neuronal basada en la arquitectura U-Net, el estándar en segmentación biomédica.

- **Encoder (Contracción):** En lugar de capas convolucionales simples, se utilizó **ResNet50** pre-entrenada con pesos de *ImageNet*. Esto permite al modelo aprovechar características visuales complejas aprendidas previamente, mejorando la detección de bordes sutiles en el tumor.
- **Decoder (Expansión):** Se utilizaron capas de *Conv2DTranspose* para recuperar la resolución original de la imagen y generar la máscara de salida.
- **Concatenación:** Se aplicaron conexiones residuales (skip connections) entre el encoder y el decoder para preservar la información espacial.

D. Configuración del Entrenamiento

- **Framework:** TensorFlow y Keras (Python).
- **Función de Pérdida (Loss Function):** Se implementó **Dice Loss**. A diferencia de la entropía cruzada, Dice Loss es superior para problemas de segmentación médica donde el área de interés (el tumor) es muy pequeña comparada con el fondo negro (desequilibrio de clases).
- **Optimizador:** Adam con una tasa de aprendizaje de $1e-4$.
- **Callbacks:** Se utilizaron *ModelCheckpoint* y *EarlyStopping* para guardar el mejor modelo y prevenir el sobreajuste (*overfitting*).

III. RESULTADOS

El modelo entrenado (unet.h5) fue sometido a pruebas con imágenes inéditas (conjunto de Test). A continuación se presentan las métricas de rendimiento obtenidas:

Tabla 1. Métricas de Evaluación del Modelo

Métrica	Valor Obtenido	Descripción
Accuracy (Exactitud)	0.99427	Precisión global de píxeles (incluyendo fondo).
F1-Score (Dice)	0.79447	Coincidencia entre la predicción y el tumor real.
IoU (Jaccard)	0.70679	Intersección sobre la Unión.
Recall (Sensibilidad)	0.85322	Capacidad de encontrar la totalidad del tumor.
Precision	0.78579	Exactitud de lo que se predijo como tumor.

Una muestra que se logra de la visualización comparativa de la imagen MRI vs la detección tumoral realizada por la segmentación IA se muestra en la Figura 1. Esta imagen no forma parte del conjunto de datos utilizado para el entrenamiento,

Comparación de Imágenes




Figura 1. Imagen MRI vs Heatmap (Segmentación IA)

IV. DESARROLLO DE LA APLICACIÓN (APP)

Para trasladar el modelo de entrenamiento a un entorno de despliegue funcional, se desarrolló una aplicación de escritorio basada en el lenguaje **Python 3.10**. El sistema fue diseñado siguiendo una arquitectura modular que separa la lógica de inferencia de la interfaz de usuario, garantizando la estabilidad del procesamiento de imágenes.

A. Pila Tecnológica

El núcleo de la aplicación se construyó sobre las siguientes librerías especializadas:

- **TensorFlow/Keras:** Para la carga del modelo y la ejecución de la inferencia neuronal.
- **OpenCV (cv2):** Para el preprocesamiento de matrices de imágenes y operaciones de visión artificial (redimensionamiento y mapas de color).
- **NumPy:** Para la manipulación eficiente de tensores y operaciones de umbralización binaria.

- **Pillow (PIL):** Para la gestión de formatos de imagen y renderizado en la interfaz gráfica.

B. Pipeline de Inferencia

El flujo de trabajo interno de la aplicación sigue una secuencia estricta de cinco etapas, implementadas en el script principal:

1. Carga del Modelo con Objetos Personalizados:

El modelo fue entrenado utilizando una función de pérdida específica, la carga del archivo `unet.h5` requiere la inyección de la función `dice_loss`. Esto asegura que la arquitectura de la red se reconstruya exactamente con los mismos parámetros matemáticos del entrenamiento.

2. Preprocesamiento de Entrada:

Las imágenes de resonancia magnética (MRI) subidas por el usuario, que pueden variar en resolución, son sometidas a una normalización geométrica y radiométrica:

- **Redimensionamiento:** La imagen se ajusta a 256 x 256 píxeles para coincidir con la capa de entrada de la U-Net.
- **Normalización:** Los valores de intensidad de los píxeles (0-255) se escalan al rango [0, 1] para facilitar la multiplicación matricial en la red neuronal.

3. Segmentación Neuronal:

El tensor procesado se introduce en el modelo para la predicción. La salida es una matriz de probabilidades donde cada píxel tiene un valor entre 0 y 1, indicando la probabilidad de pertenecer a la clase "tumor".

4. Generación del Mapa de Calor (Heatmap):

Para facilitar la interpretación clínica, no se muestra la máscara en blanco y negro. Se aplica un algoritmo de colorización (`cv2.COLORMAP_JET`) a la máscara y se fusiona con la imagen original resultando en una imagen donde el tejido tumoral aparece resaltado en contraste con el tejido cerebral sano.

C. Interfaz de Usuario y Experiencia (UX)

La interfaz fue diseñada para ser minimalista y eficiente, facilitando el uso por parte del especialista.

- **Carga Asíncrona:** El sistema permite la selección de archivos mediante el explorador nativo del sistema operativo. Figura 2.
- **Visualización Comparativa:** La aplicación presenta los resultados en un formato "lado a lado", mostrando la MRI original a la izquierda y la segmentación

asistida por IA a la derecha, permitiendo una validación visual inmediata por parte del médico. Figura 3.



Figura 2. Interfaz web minimalista

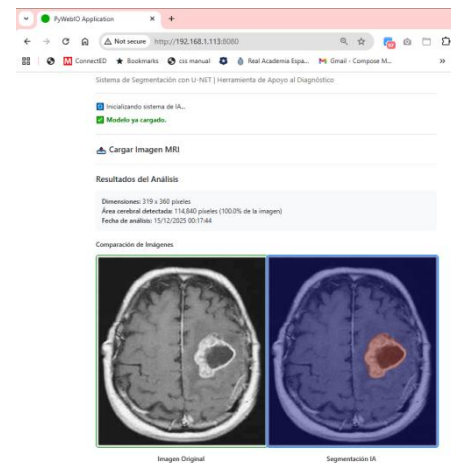


Figura 3. Comparación de imágenes

V. CONCLUSIÓN

El proyecto logró exitosamente la implementación de un sistema de segmentación de tumores cerebrales. La combinación de U-Net con ResNet50 demostró ser robusta, alcanzando una sensibilidad (Recall) del 85%, lo cual es crucial en medicina para no omitir regiones patológicas.

La aplicación desarrollada demuestra que es posible implementar algoritmos complejos de *Deep Learning* para asistir en el diagnóstico médico sin requerir hardware de servidor costoso en el punto de atención.

Aun con los resultados logrados se necesita realizar todo un conjunto de pruebas ya que para uso clínico real, el sistema requeriría:

- Validación prospectiva con casos reales.
- Aprobación de comités de ética institucionales
- Certificación regulatoria de entidades reconocidas.

- Estudios de impacto clínicos

Esta aplicación cumple con el objetivo de facilitar la visualización de estas segmentaciones, sirviendo como una base sólida para futuros sistemas de apoyo a la decisión clínica en Panamá.

VI. REFERENCIAS BIBLIOGRÁFICAS

[1] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," in *MICCAI*, 2015. [2] K. He et al., "Deep Residual Learning for Image Recognition (ResNet)," in *CVPR*, 2016. [3] F. Isensee et al., "nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation," *Nature Methods*, 2021. [4] TensorFlow Documentation. "Image Segmentation." Available: <https://www.tensorflow.org/tutorials/images/segmentation>.